

UJIAN TENGAH SEMESTER

Mid-Term Project Modelling and Analysis

Digunakan Untuk Memenuhi Tugas dan Nilai Mata Kuliah :

Predictive Analytics

Dosen Pengampu : Parma Dwi Widy Oktama



Cakrawala
University

Disusun oleh:

Suci Fransisca Sisilia Rahmat

24120500008

Data Science

Universitas Cakrawala

2026

Latar Belakang Masalah

Setiap kali sebuah bank menerima pengajuan kredit, petugas kredit sebenarnya sedang bertaruh dua arah sekaligus. Menolak pemohon yang sebenarnya layak berarti kehilangan pendapatan bunga yang seharusnya bisa didapat. Sebaliknya, menyetujui pemohon yang ternyata gagal bayar berarti bank kehilangan pokok pinjaman secara langsung, kerugian yang jauh lebih mahal daripada sekadar kehilangan peluang. Di banyak lembaga pembiayaan, keputusan semacam ini masih sangat bergantung pada penilaian manual credit analyst berdasarkan scorecard dan pengalaman pribadi, yang cenderung lambat ketika volume pengajuan besar dan rawan berbeda hasil antar analis untuk profil pemohon yang mirip.

Proyek ini dikerjakan untuk menjawab pertanyaan tersebut secara kuantitatif: **apakah riwayat data pengajuan kredit historis bisa dipakai untuk memprediksi status risiko seorang pemohon? good risk atau bad risk?**

Model yang dibangun ditujukan sebagai alat bantu pre-screening bagi credit risk analyst dan loan officer, bukan pengganti keputusan akhir mereka, mengingat sejumlah keterbatasan data yang dijelaskan di bagian akhir dokumen ini.

Dataset dan Target

Data yang dipakai adalah **South German Credit (UPDATE)**, dipublikasikan oleh UCI Machine Learning Repository kontribusi awal Dr. Hans Hofmann, diperbarui tahun 2019 oleh Dr. Ulrike Grömping (Beuth University of Applied Sciences Berlin) untuk memperbaiki sejumlah kesalahan pengkodean pada versi klasiknya. Dataset diakses pada 27 September 2026 melalui tautan resmi UCI: archive.ics.uci.edu/dataset/573/south+german+credit+update.

Dataset ini berisi **1.000 aplikasi kredit individual** di sebuah bank di Jerman Selatan yang dicatat pada tahun 1973–1975, masing-masing direkam dengan 20 atribut yang tersedia pada saat pengajuan: mulai dari status rekening giro, riwayat kredit sebelumnya, tujuan pinjaman, jumlah pinjaman, tabungan, lama bekerja, hingga usia dan status personal. Targetnya adalah `credit_risk`: 700 pemohon (70%) berlabel *good* dan 300 (30%) berlabel *bad*. Menurut penyedia data, kredit *bad* sengaja diambil lebih banyak dari proporsi aslinya (oversampling), sehingga rasio ini bukan tingkat gagal bayar yang sebenarnya. Ketimpangan ini tetap membuat metrik evaluasi harus dipilih dengan hati-hati agar tidak salah membaca model yang “kelihatan akurat” padahal tidak berguna.

Audit kualitas data tidak menemukan nilai kosong maupun baris duplikat, tetapi data belum siap dimodelkan: semua kolom berupa kode angka yang harus dipisah menjadi variabel numerik, ordinal, dan nominal lalu di-encode, dan jumlah kredit telah ditransformasi dengan cara yang tidak diketahui. Beberapa kode seperti “tidak punya rekening giro” sengaja dipertahankan sebagai kategori tersendiri karena justru mengandung sinyal bisnis yang memberikan insight pada akhirnya. Tidak ditemukan variabel yang membocorkan target / data leakage, seluruh 20 prediktor adalah informasi yang sudah tersedia pada saat pengajuan, sehingga aman dipakai untuk skenario prediksi *at origination* tanpa risiko *data leakage*.

Metode yang Dibandingkan

Sebagai pembanding minimum, dipakai **baseline majority class** yang selalu menebak “good”, akurasi otomatis 70% tetapi sama sekali tidak mendeteksi satu pun pemohon berisiko (precision dan recall kelas “bad” keduanya nol). Baseline ini menjadi patokan: model yang dibangun harus jelas lebih berguna dari sekadar tebakan naif tersebut.

Tiga model kemudian dilatih di atas data yang sama, dengan preprocessing (scaling numerik dan one-hot encoding variabel nominal) yang dibungkus dalam satu Pipeline dan hanya di-fit pada data latih untuk mencegah kebocoran informasi ke data uji. Split dilakukan 80:20 secara stratified terhadap target, dengan `random_state=42` yang konsisten di seluruh model agar hasilnya reproducible.

- **Logistic Regression** — dipilih sebagai model linear pembanding yang koefisiennya mudah dijelaskan ke analis kredit yang belum tentu familiar dengan model black-box.
- **Random Forest** — model ensemble berbasis pohon yang tahan terhadap outlier dan campuran tipe variabel, serta relatif tidak mudah overfit pada data berukuran sedang seperti ini.

- **XGBoost** — model gradient boosting yang dipilih karena kemampuannya menangkap interaksi non-linear antar variabel dan mendukung penanganan ketidakseimbangan kelas secara langsung lewat parameter `scale_pos_weight`.

Ketidakseimbangan kelas (70:30) ditangani lewat pembobotan kelas (`class_weight='balanced'` pada dua model pertama, `scale_pos_weight` pada XGBoost) — bukan lewat oversampling sintetis, agar keaslian data tetap terjaga. Sebagai validasi tambahan, dilakukan 5-fold stratified cross-validation pada data latih (ROC-AUC: Logistic Regression 0.779 ± 0.038 , Random Forest 0.790 ± 0.038 , XGBoost 0.783 ± 0.029), yang menunjukkan performa ketiga model relatif stabil dan tidak ada yang mencolok overfit terhadap satu split tertentu. Sebagai eksperimen tambahan di luar ketentuan minimum tugas, dilakukan juga GridSearchCV untuk menguji apakah tuning hyperparameter mengubah kesimpulan pemilihan model.

Metrik utama yang dipakai adalah recall kelas “bad” dan ROC-AUC, dengan precision dan F1-score (per kelas maupun keseluruhan, macro dan weighted) sebagai pendukung. Alasannya murni bisnis: *false negative*, model bilang “good” padahal sebenarnya “bad” jauh lebih mahal bagi bank dibanding *false positive*, karena bank kehilangan seluruh pokok pinjaman pada kasus gagal bayar. Akurasi keseluruhan sengaja tidak dijadikan metrik utama, karena seperti ditunjukkan baseline, akurasi tinggi bisa dicapai model yang sama sekali tidak berguna pada kelas minoritas.

Hasil Utama

Pada data uji (200 aplikasi yang belum pernah dilihat model selama pelatihan, terdiri atas 60 pemohon bad dan 140 good), ketiga model konsisten mengungguli baseline pada dimensi yang paling penting secara bisnis:

Tabel 1. Kinerja model pada 200 data uji (60 pemohon bad, 140 pemohon good)

Model	Akurasi	ROC-AUC	Recall (bad)	Precision (bad)	F1 (bad)	F1 macro	Bad lolos (FN)	Good ditolak (FP)
Baseline	0,700	0,500	0,000	0,000	0,000	0,412	60	0
Logistic Regression (default)	0,755	0,847	0,783	0,566	0,657	0,733	13	36
Logistic Regression (Tuned)	0,760	0,850	0,800	0,571	0,667	0,740	12	36
Random Forest (default)	0,765	0,830	0,650	0,600	0,624	0,727	21	26
Random Forest (Tuned)	0,780	0,816	0,633	0,633	0,633	0,738	22	22
XGBoost (default)	0,755	0,814	0,650	0,582	0,614	0,717	21	28
XGBoost (Tuned)	0,755	0,801	0,633	0,585	0,608	0,715	22	27

FN = pemohon bad yang diprediksi good (lolos); FP = pemohon good yang diprediksi bad (ditolak). Baris tebal = model yang direkomendasikan.

Meski XGBoost sempat direncanakan sebagai model andalan, pada hasilnya Logistic Regression justru mencatat ROC-AUC dan recall kelas “bad” tertinggi (mendeteksi 47 dari 60 pemohon bad), sedikit mengungguli dua model ensemble. Ini kemungkinan besar disebabkan ukuran data latih yang tergolong kecil (800 baris), yang belum cukup besar untuk membuat kapasitas nonlinear Random Forest dan XGBoost benar-benar unggul dibanding model linear dengan regularisasi yang baik, ditambah sebagian besar sinyal prediktif di dataset ini memang cenderung bersifat monoton terhadap target. Sementara itu, Random Forest mencatat akurasi dan precision kelas “bad” tertinggi, menandakan model ini paling seimbang antara menangkap nasabah berisiko dan tidak terlalu sering salah menolak nasabah yang sebenarnya baik.

Eksperimen GridSearchCV memberi perbaikan namun moderat, tidak berubah secara drastis. Hasil tuning ini tidak mengubah kesimpulan utama, hanya mempertegasnya. Perlu dicatat bahwa selisih antar model relatif kecil: skor cross-validation (ROC-AUC 0,78–0,79) lebih rendah daripada skor data uji, dan data uji hanya memuat 60 pemohon bad, sehingga perbedaan beberapa pemohon tidak boleh dibaca terlalu tegas.

Analisis feature importance (dihitung dari model default) pada kedua model berbasis pohon sepakat menempatkan status rekening giro sebagai prediktor paling berpengaruh, konsisten dengan pola yang sudah terlihat sejak tahap eksplorasi data dan analisis korelasi. Tenor kredit (duration) juga menonjol pada Random Forest meski lebih rendah pada XGBoost, sedangkan variabel tabungan dan riwayat kredit konsisten muncul di jajaran atas kedua model. Perlu ditekankan bahwa feature importance di sini mengukur kontribusi prediktif,

bukan hubungan sebab-akibat, tingginya pengaruh status rekening giro tidak bisa langsung dibaca sebagai “membuka rekening giro akan membuat seseorang lebih layak kredit”.

Model yang Direkomendasikan

Random Forest (setelah tuning) direkomendasikan sebagai model utama, karena menawarkan kombinasi terbaik antara F1 keseluruhan (weighted) tertinggi, akurasi tertinggi, dan trade-off precision-recall paling seimbang di antara seluruh model yang diuji, cocok dipakai sebagai kebijakan default screening yang tidak terlalu agresif menolak nasabah baik maupun terlalu longgar meloloskan nasabah berisiko. Perlu dicatat bahwa pada dua metrik utama (recall “bad” dan ROC-AUC), Logistic Regression (Tuned) sebenarnya lebih unggul. Random Forest (Tuned) dipilih sebagai default karena hanya menolak 22 dari 140 pemohon baik (16%), dibanding 36 (26%) pada Logistic Regression (Tuned), dengan konsekuensi 22 dari 60 pemohon bad lolos (dibanding 12).

Namun bila prioritas bisnis bank adalah seagresif mungkin menangkap calon nasabah gagal bayar, misalnya karena biaya kredit macet dianggap jauh lebih mahal daripada kehilangan satu nasabah baik, **Logistic Regression (setelah tuning)** menjadi pilihan yang lebih rasional, karena recall kelas “bad”-nya paling tinggi di antara seluruh model (0,800). Secara hitungan sederhana, Logistic Regression (Tuned) lebih murah selama satu pemohon bad yang lolos dianggap lebih dari sekitar 1,4 kali lebih mahal daripada satu pemohon baik yang ditolak; rasio 5:1 yang disarankan dokumentasi versi klasik dataset ini termasuk dalam kondisi tersebut. Keputusan akhir semestinya bergantung pada cost matrix riil bank tersebut, bukan semata angka F1 atau akurasi rata-rata.

Rekomendasi Praktis

Model ini sebaiknya dipakai sebagai alat bantu pre-screening, bukan pengambil keputusan tunggal terutama untuk pemohon dengan skor probabilitas mendekati ambang batas keputusan, yang tetap perlu ditinjau manual oleh analis. Skor tersebut juga bukan peluang gagal bayar yang sebenarnya karena kredit bad pada data sengaja diperbanyak. Perhatian khusus disarankan untuk pemohon dengan tenor kredit panjang dan status rekening giro lemah (tanpa rekening atau saldo negatif): pada seluruh data, kelompok dengan tenor di atas 24 bulan dan status tersebut (144 pemohon) 60% berlabel bad, dibanding 30% secara keseluruhan. Bank dengan kebijakan konservatif terhadap risiko gagal bayar disarankan memakai Logistic Regression dengan threshold yang bisa disesuaikan sesuai risk appetite; bank yang ingin menjaga volume approval tetap sehat sambil mengontrol risiko lebih cocok memakai Random Forest.

Keterbatasan

Beberapa hal perlu diingat sebelum hasil ini dijadikan dasar membuat kebijakan. Pertama, ukuran data (1.000 baris, dengan hanya 200 baris data uji dan 60 di antaranya pemohon bad) tergolong kecil untuk standar machine learning modern, sehingga estimasi performa punya varians yang cukup besar antar kemungkinan split data; tujuh model yang dibandingkan pada data uji yang sama juga membuat hasil terbaik bisa sedikit terlalu optimistis. Kedua, data ini berasal dari sebuah bank di Jerman Selatan pada tahun 1973–1975 dengan nilai kredit dalam Deutsche Mark; pembaruan tahun 2019 hanya mengoreksi pengkodean, bukan memperbarui isi datanya, dan proporsi kredit bad sudah diperbanyak oleh penyedia data. Pola sosial-ekonomi dan struktur perbankan di dalamnya tidak serta-merta bisa digeneralisasi ke konteks perbankan Indonesia tanpa validasi ulang pada data lokal. Ketiga, seperti sudah disinggung, feature importance bukan bukti kausalitas dan idealnya divalidasi lebih lanjut lewat studi kausal sebelum dipakai sebagai dasar kebijakan baku; selain itu, karena jumlah kredit ditransformasi dengan cara yang tidak diketahui, fitur beban angsuran (installment_burden) yang dibuat darinya hanya berupa pendekatan. Keempat, dataset ini memuat atribut yang berpotensi menimbulkan bias diskriminatif, yaitu status personal (menggabungkan status pernikahan dan jenis kelamin dalam satu kode), status pekerja asing (foreign_worker, yang bahkan masuk 10 besar fitur terpenting XGBoost), dan usia; proyek ini belum melakukan audit fairness secara eksplisit terhadap variabel-variabel tersebut. Hal ini menjadi relevan bila model serupa diadaptasi untuk lembaga keuangan di Indonesia yang berada di bawah pengawasan OJK, karena prinsip perlindungan konsumen OJK menuntut keadilan dalam pemberian kredit, sehingga model yang dilatih dari data seperti ini baru layak dipertimbangkan untuk penggunaan nyata setelah lolos audit fairness dan divalidasi pada data historis lokal yang lebih besar dan lebih baru.