

UJIAN TENGAH SEMESTER

Mid-Term Project Modelling and Analysis

Digunakan Untuk Memenuhi Tugas dan Nilai Mata Kuliah :

Predictive Analytics

Dosen Pengampu : Parma Dwi Widy Oktama



Cakrawala
University

Disusun oleh:

Suci Fransisca Sisilia Rahmat

24120500008

Data Science

Universitas Cakrawala

2026

Latar Belakang Masalah

Setiap kali sebuah bank menerima pengajuan kredit, petugas kredit sebenarnya sedang bertaruh dua arah sekaligus. Menolak pemohon yang sebenarnya layak berarti kehilangan pendapatan bunga yang seharusnya bisa didapat. Sebaliknya, menyetujui pemohon yang ternyata gagal bayar berarti bank kehilangan pokok pinjaman secara langsung, kerugian yang jauh lebih mahal daripada sekadar kehilangan peluang. Di banyak lembaga pembiayaan, keputusan semacam ini masih sangat bergantung pada penilaian manual credit analyst berdasarkan scorecard dan pengalaman pribadi, yang cenderung lambat ketika volume pengajuan besar dan rawan berbeda hasil antar analis untuk profil pemohon yang mirip.

Proyek ini dikerjakan untuk menjawab pertanyaan tersebut secara kuantitatif: **apakah riwayat data pengajuan kredit historis bisa dipakai untuk memprediksi status risiko seorang pemohon? good risk atau bad risk? sebelum keputusan akhir diambil manusia?**

Model yang dibangun ditujukan sebagai alat bantu pre-screening bagi credit risk analyst dan loan officer, bukan pengganti keputusan akhir mereka, mengingat sejumlah keterbatasan data yang dijelaskan di bagian akhir dokumen ini.

Dataset dan Target

Data yang dipakai adalah **South German Credit (UPDATE)**, dipublikasikan oleh UCI Machine Learning Repository kontribusi awal Dr. Hans Hofmann, diperbarui tahun 2019 oleh Dr. Ulrike Grömping (Beuth University of Applied Sciences Berlin) untuk memperbaiki sejumlah kesalahan pengkodean pada versi klasiknya. Dataset diakses pada 27 September 2026 melalui tautan resmi UCI: archive.ics.uci.edu/dataset/573/south+german+credit+update.

Dataset ini berisi **1.000 aplikasi kredit individual** di sebuah bank di Jerman Selatan, masing-masing direkam dengan 20 atribut yang tersedia pada saat pengajuan : mulai dari status rekening giro, riwayat kredit sebelumnya, tujuan pinjaman, jumlah pinjaman, tabungan, lama bekerja, hingga usia dan status personal. Targetnya adalah `credit_risk`: 700 pemohon (70%) berlabel *good* dan 300 (30%) berlabel *bad*. Ketimpangan ini bukan cacat data, melainkan gambaran wajar bahwa bank memang menyetujui mayoritas pengajuan yang masuk, sehingga metrik evaluasi harus dipilih dengan hati-hati agar tidak salah membaca model yang “kelihatan akurat” padahal tidak berguna.

Audit kualitas data tidak menemukan nilai kosong maupun baris duplikat. Beberapa kode seperti “tidak punya rekening giro” sengaja dipertahankan sebagai kategori tersendiri karena justru mengandung sinyal bisnis, bukan dianggap data hilang. Tidak ditemukan variabel yang membocorkan target, seluruh 20 prediktor adalah informasi yang sudah tersedia pada saat pengajuan, sehingga aman dipakai untuk skenario prediksi *at origination* tanpa risiko *data leakage*.

Metode yang Dibandingkan

Sebagai pembanding minimum, dipakai **baseline majority class** yang selalu menebak “good”, akurasi otomatis 70% tetapi sama sekali tidak mendeteksi satu pun pemohon berisiko (precision dan recall kelas “bad” keduanya nol). Baseline ini menjadi patokan: model yang dibangun harus jelas lebih berguna dari sekadar tebakan naif tersebut.

Tiga model kemudian dilatih di atas data yang sama, dengan preprocessing (scaling numerik dan one-hot encoding variabel nominal) yang dibungkus dalam satu Pipeline dan hanya di-*fit* pada data latih untuk mencegah kebocoran informasi ke data uji. Split dilakukan 80:20 secara *stratified* terhadap target, dengan `random_state=42` yang konsisten di seluruh model agar hasilnya reproducible.

- **Logistic Regression** — dipilih sebagai model linear pembanding yang koefisiennya mudah dijelaskan ke analis kredit yang belum tentu familiar dengan model *black-box*.
- **Random Forest** — model ensemble berbasis pohon yang tahan terhadap outlier dan campuran tipe variabel, serta relatif tidak mudah *overfit* pada data berukuran sedang seperti ini.
- **XGBoost** — model gradient boosting yang dipilih karena kemampuannya menangkap interaksi non-linear antar variabel dan mendukung penanganan ketidakseimbangan kelas secara langsung lewat parameter `scale_pos_weight`.

Ketidakseimbangan kelas (70:30) ditangani lewat pembobotan kelas (`class_weight='balanced'` pada dua model per-tama, `scale_pos_weight` pada XGBoost) — bukan lewat oversampling sintesis, agar keaslian data tetap terjaga. Sebagai validasi tambahan, dilakukan 5-fold *stratified cross-validation* pada data latih (ROC-AUC: Logistic Regression 0.779 ± 0.038 , Random Forest 0.790 ± 0.038 , XGBoost 0.783 ± 0.029), yang menunjukkan performa ketiga model relatif stabil dan tidak ada

yang mencolok *overfit* terhadap satu split tertentu. Sebagai eksperimen tambahan di luar ketentuan mini-mum tugas, dilakukan juga GridSearchCV untuk menguji apakah *tuning* hyperparameter mengubah kesimpulan pemilihan model.

Metrik utama yang dipakai adalah recall kelas “bad” dan ROC-AUC, dengan precision dan F1-score (per kelas maupun keseluruhan, macro dan weighted) sebagai pendukung. Alasannya murni bisnis: *false negative* — model bilang “good” padahal sebenarnya “bad” — jauh lebih mahal bagi bank dibanding *false positive*, karena bank kehilangan seluruh pokok pinjaman pada kasus gagal bayar. Akurasi keseluruhan sengaja tidak dijadikan metrik utama, karena seperti ditunjukkan baseline, akurasi tinggi bisa dicapai model yang sama sekali tidak berguna pada kelas minoritas.

Hasil Utama

Pada data uji (200 aplikasi yang belum pernah dilihat model selama pelatihan), ketiga model konsisten mengungguli baseline pada dimensi yang paling penting secara bisnis:

Model	Akurasi	ROC-AUC	Recall (bad)	Precision (bad)	F1 (bad)	F1 Macro
Baseline	0,700	0,500	0,000	0,000	0,000	0,412
Logistic Regression	0,755	0,847	0,783	0,566	0,657	0,733
Random Forest	0,765	0,830	0,650	0,600	0,624	0,727
XGBoost	0,755	0,814	0,650	0,582	0,614	0,717

Meski **XGBoost** sempat direncanakan sebagai model andalan, namun pada hasilnya model yg perform dengan baik adalah **Logistic Regression justru mencatat ROC-AUC dan recall kelas “bad” tertinggi**, sedikit mengungguli dua model ensemble. Ini kemungkinan besar disebabkan ukuran data latih yang tergolong kecil (800 baris), yang belum cukup besar untuk membuat kapasitas non-linear Random Forest dan XGBoost benar-benar unggul dibanding model linear dengan regularisasi yang baik, ditambah sebagian besar sinyal prediktif di dataset ini memang cenderung bersifat monoton terhadap target. Sementara itu, **Random Forest mencatat akurasi dan precision kelas “bad” tertinggi**, menandakan model ini paling seimbang antara menangkap nasabah berisiko dan tidak terlalu sering salah menolak nasabah yang sebenarnya baik.

Eksperimen GridSearchCV memberi perbaikan namun moderat, tidak perform secara drastis. Random Forest (Tuned) naik menjadi akurasi 0,780 dengan F1 macro/weighted tertinggi di antara seluruh model yang diuji (0,738 dan 0,780), sementara Logistic Regression (Tuned) mencatat recall kelas “bad” tertinggi secara keseluruhan, yaitu 0,800, dengan ROC-AUC 0,850. Hasil tuning ini tidak mengubah kesimpulan utama, hanya mempertegasnya.

Model	Akurasi	ROC-AUC	F1 (macro)	F1 (weighted)	Recall (bad)	Precision (bad)	F1 (bad)	F1 (good)
Random Forest (default)	0.765	0.830	0.727	0.768	0.650	0.600	0.624	0.829
Random Forest (Tuned)	0.780	0.816	0.738	0.780	0.633	0.633	0.633	0.843
XGBoost (default)	0.755	0.814	0.717	0.759	0.650	0.582	0.614	0.821
XGBoost (Tuned)	0.755	0.801	0.715	0.758	0.633	0.585	0.608	0.822
Logistic Regression (default)	0.755	0.847	0.733	0.764	0.783	0.566	0.657	0.809
Logistic Regression (Tuned)	0.760	0.850	0.740	0.769	0.800	0.571	0.667	0.813

Analisis *feature importance* pada kedua model berbasis pohon sepakat menempatkan **status rekening giro** dan **tenor kredit (duration)** sebagai dua prediktor paling berpengaruh, konsisten dengan pola yang sudah terlihat sejak tahap eksplorasi data dan analisis korelasi. Variabel tabungan, riwayat kredit, dan keberadaan penjamin lain juga secara konsisten muncul di jajaran atas kedua model. Perlu ditekankan bahwa *feature importance* disini mengukur kontribusi prediktif, bukan hubungan sebab-akibat, tingginya pengaruh status rekening giro tidak bisa langsung dibaca sebagai “membuka rekening giro akan membuat seseorang lebih layak kredit”.

Model yang Direkomendasikan

Random Forest (setelah tuning) direkomendasikan sebagai model utama, karena menawarkan kombinasi terbaik antara F1 keseluruhan tertinggi, akurasi tertinggi, dan trade-off precision-recall paling seimbang di antara seluruh model yang diuji, cocok dipakai sebagai kebijakan default screening yang tidak terlalu agresif menolak nasabah baik maupun terlalu longgar meloloskan nasabah berisiko.

Namun bila prioritas bisnis bank adalah seagresif mungkin menangkap calon nasabah gagal bayar, misalnya karena biaya kredit macet dianggap jauh lebih mahal daripada kehilangan satu nasabah baik, **Logistic Regression (setelah tuning) menjadi pilihan yang lebih rasional**, karena recall kelas “bad”-nya paling tinggi di antara seluruh model (0,800). Keputusan akhir semestinya bergantung pada *cost matrix* riil bank tersebut, bukan semata angka F1 atau akurasi rata-rata.

Rekomendasi Praktis

Model ini sebaiknya dipakai sebagai **alat bantu pre-screening**, bukan pengambil keputusan tunggal terutama untuk pemohon dengan skor probabilitas mendekati ambang batas keputusan, yang tetap perlu ditinjau manual oleh analis. Perhatian khusus disarankan untuk pemohon dengan **tenor kredit panjang dan tanpa rekening giro aktif**, karena kombinasi ini paling konsisten muncul sebagai sinyal risiko di seluruh model dan tahap analisis. Bank dengan kebijakan konservatif terhadap risiko gagal bayar disarankan memakai Logistic Regression dengan threshold yang bisa disesuaikan sesuai *risk appetite*; bank yang ingin menjaga volume approval tetap sehat sambil mengontrol risiko lebih cocok memakai Random Forest.

Keterbatasan

Beberapa hal perlu diingat sebelum hasil ini dijadikan dasar kebijakan nyata. Pertama, ukuran data (1.000 baris, dengan hanya 200 baris data uji) tergolong kecil untuk standar machine learning modern, sehingga estimasi performa punya varians yang cukup besar antar kemungkinan split data. Kedua, data ini berasal dari konteks perbankan Jerman era 1990-an meski versi datanya diperbarui tahun 2019, pola sosial-ekonomi dan struktur perbankan di dalamnya tidak serta-merta bisa digeneralisasi ke konteks perbankan Indonesia tanpa validasi ulang pada data lokal. Ketiga, seperti sudah disinggung, *feature importance* bukan bukti kausalitas dan idealnya divalidasi lebih lanjut lewat studi kausal sebelum dipakai sebagai dasar kebijakan baku. Keempat, variabel status personal pada dataset ini menggabungkan status pernikahan dan jenis kelamin dalam satu kode, yang berpotensi menimbulkan bias diskriminatif bila dipakai tanpa pengawasan; proyek ini belum melakukan audit *fairness* secara eksplisit terhadap variabel semacam ini, sehingga menjadi langkah lanjutan penting, terlebih mengingat prinsip perlindungan konsumen OJK terkait keadilan pemberian kredit di Indonesia, sebelum model semacam ini dipertimbangkan untuk penggunaan nyata, di samping kebutuhan validasi pada data historis yang lebih besar dan lebih baru.